A3 — Guia de execução: Modelagem de bancos de dados a partir de conjuntos, relações e funções

Integrantes: Bruno Nunes, Eduardo Pickler, Júlio Cesar, Gabriel Tomazine Torres e Matheus Pinter Silva.

1. Auditoria do banco no Supabase

Analisei o diagrama que vocês enviaram (tabelas Pedidos, Cliente e Produtos) e testei o modelo corrigido com os dados reais do CSV. As chaves primárias e as duas chaves estrangeiras (Pedidos → Cliente e Pedidos → Produtos) estão certas. Os problemas são estes:

#	Problema	Por que importa	Correção
1	`region` está na tabela Cliente	**11 clientes aparecem em mais de uma região** (ex.: o cliente 1871 tem pedidos em East, South e North). Então customer_id → region não é dependência funcional. Cada cliente só guardaria uma região e os totais por região mudariam.	Mover `region` para Pedidos (a região é atributo do pedido)
2	`unit_price`, `discount`, `customer_rating` e `revenue` são float4	Ponto flutuante de 32 bits acumula erro nas somas, e a receita total não fecharia em 216.665,61	Usar NUMERIC(10,2), NUMERIC(3,2) e NUMERIC(2,1)
3	Nomes com maiúscula: "Pedidos", "Cliente", "Produtos"	No Postgres viram identificadores com aspas. Qualquer consulta sem aspas dá erro "relation does not exist". Também há mistura de singular e plural.	Padronizar em minúsculas: clientes, produtos, pedidos

#	Problema	Por que importa	Correção
4	customer_id, product_id e as métricas aceitam nulo (losango vazio no diagrama)	Um pedido sem cliente ou sem produto quebra a integridade referencial	NOT NULL em todas as colunas
5	Sem restrições CHECK	O banco aceitaria nota 9, desconto negativo ou região inexistente	CHECK em region, payment_method, quantity, discount e customer_rating
6	O ícone # nas chaves sugere coluna identity (autonumeração)	Com identity, o INSERT com o order_id do CSV falha	O script recria as tabelas sem identity

Observações de modelagem que valem uma nota no texto:

- **Produtos guarda só 4 linhas** (as categorias). O `unit_price` fica em Pedidos porque varia a cada pedido (de 17,05 a 599,32 dentro da mesma categoria).
- **`revenue` é calculado** (quantity × unit_price × (1 − discount)). Em rigor, isso é uma dependência transitiva e fere a 3FN. Mantivemos a coluna de propósito, como redundância controlada, para reproduzir o dashboard e servir de auditoria. Comprovamos que ela bate com a fórmula em todos os 199 pedidos.

Como aplicar: no SQL Editor do Supabase, rodem nesta ordem: `01_recriar_esquema.sql` (apaga as tabelas atuais e recria), `02_inserts.sql` (carrega os dados) e `03_verificacao.sql` (confere tudo). Se quiserem que eu confira o resultado, rodem `00_auditoria_schema.sql` e me mandem o print.

Contagem real do dataset: são **199 registros** (order_id de 10001 a 10199, de 01/01/2022 a 18/07/2022). O arquivo tem 200 linhas porque conta o cabeçalho. Usem 199 em todo o trabalho. Há 183 clientes distintos, e 14 deles têm mais de um pedido (máximo de 3).

2. Checagem com o roteiro do professor

O professor pede	Situação no índice atual	Ajuste
Definição de conjunto e produto cartesiano	Coberto (Cap. 2)	—
Relação binária	Coberto (Cap. 3)	—

O professor pede	Situação no índice atual	Ajuste
Função, domínio, contradomínio e imagem	**Ausente**	Incluir no Cap. 3 (seção 3.3). O tema se chama "conjuntos, relações e **funções**", então não pode faltar.
Conectar à modelagem de tabelas, chaves e relacionamentos	Coberto (Cap. 3 e 5)	—
Comparar muitos-para-muitos, um-para-muitos e **funções bem definidas**	Parcial (só 1:N e N:M)	Incluir a comparação relação × função no Cap. 3
Slides: exemplo acadêmico (Alunos, Disciplinas, Professores)	Não previsto	Usar como exemplo didático no Cap. 3 e nos slides 4 e 5
Slides: diagramas que mostrem quando uma relação é ou não função	Não previsto	Slide 5 (diagrama de setas)
Mínimo de 20 páginas e 10 slides	Previsto	Ver orçamento de páginas abaixo

Outras lacunas do índice: a **normalização até a 3FN** não aparece em nenhum capítulo (vai na seção 5.4) e o **dashboard do Looker Studio** também não (vai na seção 6.3).

Índice revisado e orçamento de páginas

Capítulo	Páginas
1. Introdução, objetivos e justificativa	2
2. Fundamentação I: conjuntos, subconjuntos e produto cartesiano	3
3. Fundamentação II: relações binárias, funções, mapeamentos e chaves	4
4. Fundamentação III: álgebra relacional	3
5. Estudo de caso: dataset e modelagem	5
6. Validação empírica e conclusão	3
Total do corpo do texto	**20**

Capa, sumário e referências ficam fora dessa conta. Assim o mínimo de 20 páginas é cumprido só pelo desenvolvimento.

3. O que escrever em cada capítulo

Cap. 1 — Introdução, objetivos e justificativa (2 págs.)

- **Contexto:** o que é um SGBD e por que dados inter-relacionados exigem estrutura (Silberschatz et al., 2012). Aproveitem a introdução que já está escrita.
- **Problema:** a modelagem de dados não nasce só de diagramas, mas de estruturas formais (é a ideia central do tema).
- **Objetivo geral:** mostrar como conjuntos, relações e funções fundamentam um banco relacional.
- **Objetivos específicos:** (i) definir os conceitos; (ii) modelar o dataset em 3FN; (iii) expressar consultas em álgebra relacional e SQL; (iv) validar os resultados por amostragem.
- **Justificativa:** rigor, integridade dos dados e reprodutibilidade.
- **Metodologia resumida:** dataset de e-commerce, Supabase (PostgreSQL), Looker Studio.
- **Organização do trabalho:** uma frase por capítulo.

Cap. 2 — Conjuntos, subconjuntos e produto cartesiano (3 págs.)

- **2.1 Conjuntos:** pertinência ($\in$), conjunto vazio, cardinalidade $|A|$. Exemplo do dataset: Regiões = {North, South, East, West}, Pagamentos = {Card, COD, Wallet}, Categorias = {Beauty, Clothing, Electronics, Home}.
- **2.2 Subconjuntos e operações:** $A \subseteq B$, união, interseção, diferença, complemento. Fórmula $|A \cup B| = |A| + |B| - |A \cap B|$ (a regra da adição que vocês viram em Probabilidade).
- **2.3 Produto cartesiano:** $A \times B = \{(a, b) : a \in A \text{ e } b \in B\}$ e $|A \times B| = |A| \cdot |B|$. Tupla ordenada. Exemplo: Região × Pagamento tem $4 \cdot 3 = 12$ pares, e os 12 aparecem no dataset.
- **2.4 Da teoria à tabela:** uma relação n-ária é um subconjunto $R \subseteq D_1 \times \ldots \times D_n$, e cada linha da tabela é uma tupla desse subconjunto. Clientes × Produtos tem $183 \cdot 4 = 732$ tuplas possíveis. Pedidos tem 199 linhas, ou seja, **um subconjunto** do espaço de possibilidades.
- **Exemplo prático do projeto:** o dataset de e-commerce que será implementado no Supabase.

Cap. 3 — Relações binárias, funções, mapeamentos e chaves (4 págs.)

- **3.1 Relação binária:** R ⊆ A × B, com domínio e imagem.
- **3.2 Propriedades:** reflexiva, simétrica, transitiva, e relação de equivalência. Exemplo: "mesma região" entre pedidos é uma relação de equivalência, e as classes de equivalência são os grupos do GROUP BY.
- **3.3 Funções (seção que faltava):** f: A → B, em que cada elemento de A se associa a **exatamente um** de B. Definam domínio, contradomínio e imagem, e depois injetora, sobrejetora e bijetora.
- **3.4 Relação × função:** uma relação só é função se todo elemento do domínio tem um e apenas um correspondente. Exemplo central: f: Pedidos → Clientes, f(order_id) = customer_id é função, pois cada pedido tem um único cliente. A relação inversa (Cliente → Pedidos) **não é função**, porque 14 clientes têm mais de um pedido. **A chave estrangeira é a implementação de uma função.**
- **3.5 Mapeamentos 1:1, 1:N e N:M:** com o exemplo acadêmico do professor. Professor leciona Disciplina é 1:N (cada disciplina tem um professor responsável, logo Disciplinas → Professores é função). Aluno cursa Disciplina é N:M e exige uma tabela associativa Matrículas ⊆ Alunos × Disciplinas, que se desfaz em duas funções (Matrículas → Alunos e Matrículas → Disciplinas).
- **3.6 Chaves:** superchave, chave candidata, chave primária e chave estrangeira. Dependência funcional X → Y. No dataset, order_id → todos os atributos vale, mas customer_id → region **não** vale (contraexemplo: cliente 1871).

Cap. 4 — Álgebra relacional (3 págs.)

- **4.1 Operadores fundamentais:** seleção σ, projeção π, união ∪, diferença −, produto cartesiano × e renomeação ρ.
- **4.2 Operadores derivados:** interseção (R ∩ S = R − (R − S)), junção ⋈ (uma seleção sobre o produto cartesiano seguida de projeção) e divisão. Mencionem a agregação γ como extensão.
- **4.3 Compatibilidade para união:** ∪, ∩ e − exigem relações com o mesmo esquema.
- **4.4 Álgebra × SQL:** σ = WHERE, π = SELECT, × = CROSS JOIN, ⋈ = INNER JOIN, ∪ = UNION, ∩ = INTERSECT, − = EXCEPT. Os dois autores citados (Date, 1990; Silberschatz et al., 2012) tratam a álgebra relacional como base da linguagem de consulta.
- **4.5 Consultas do projeto** (ver a seção 4 deste guia e o arquivo `04_consultas_algebra_relacional.sql`).

Cap. 5 — Estudo de caso: dataset, modelagem e normalização (5 págs.)

- **5.1 O dataset:** 199 pedidos, 12 atributos, período 01/01/2022 a 18/07/2022. Domínios: quantidade de 1 a 7, desconto de 0 a 0,35, prazo de entrega de 1 a 11 dias, nota de 1 a 5. Totais: receita de 216.665,61 e nota média de 2,98.
- **5.2 Estrutura desnormalizada:** a tabela única R(order_id, order_date, customer_id, product_category, region, quantity, unit_price, discount, payment_method, delivery_days, customer_rating, revenue).
- **5.3 Dependências funcionais encontradas:** order_id → todos os demais; product_category ↔ product_id (chave substituta); quantity, unit_price, discount → revenue (derivada); customer_id ↛ region.
- **5.4 Normalização:** 1FN (valores atômicos, atende), 2FN (chave simples, atende), 3FN (decomposição em Clientes, Produtos e Pedidos). Contem o achado sobre region e a nota sobre revenue.
- **5.5 Decomposição sem perda:** R = Pedidos ⋈ Clientes ⋈ Produtos. Prova empírica: a junção devolve 199 linhas, as mesmas de Pedidos.
- **5.6 Esquema físico:** DDL do arquivo `01_recriar_esquema.sql`, com PK, FK, NOT NULL e CHECK. Incluam o diagrama ER (print do Supabase depois da correção).
- **5.7 Integridade referencial:** mostrem que o banco rejeita um pedido com customer_id inexistente (foi testado: a FK bloqueia o órfão).

Cap. 6 — Validação empírica, dashboard e conclusão (3 págs.)

- **6.1 Método de verificação por amostragem** (seção 5 deste guia).
- **6.2 Resultados:** tabela comparando conferência manual × SQL × dashboard.
- **6.3 Dashboard no Looker Studio:** cartões com receita total (216.665,61), total de pedidos (199) e avaliação média (2,98), barras por categoria e tabela de auditoria.
- **6.4 Limitações:** amostra pequena (199 registros) e dados sem chave natural de produto.
- **6.5 Conclusão:** síntese de conjuntos → relações → funções → tabelas. Relevância da matemática discreta para bancos de dados, e perspectivas (grandes volumes de dados, NoSQL).

4. Álgebra relacional e SQL: o que cada consulta prova

Notação: C = clientes, P = produtos, T = pedidos. Todas foram executadas sobre os dados reais.

Consulta	Álgebra relacional	Resultado
a1) Produto cartesiano	C × P	732 tuplas (183 · 4)
a2) Produto cartesiano maior	T × C	36.417 tuplas (199 · 183)
a3) Junção como seleção	σ(T.customer_id = C.customer_id)(T × C)	199 tuplas
a4) Junção (INNER JOIN)	T ⋈ C ⋈ P	199 tuplas (igual a a3)
b) Interseção	π(cliente)(σ(cat = Electronics)(T ⋈ P)) ∩ π(cliente)(σ(cat = Beauty)(T ⋈ P))	{1871, 1955}
c) Diferença	π(cliente)(σ(region = South)(T)) − π(cliente)(σ(cat = Home)(T ⋈ P))	29 clientes (de 40 com pedido em South)
d1) União de conjuntos	Electronics ∪ Beauty	91 clientes = 69 + 24 − 2
d2) União de perfis	γ(region)(T) ∪ γ(payment_method)(T)	7 linhas (4 regiões e 3 pagamentos)

O destaque didático é o par **a3 × a4**: a junção é uma seleção feita sobre o produto cartesiano, e as duas formas dão exatamente 199 tuplas.

Atenção na consulta c): como a região é atributo do pedido, "cliente da região South" significa cliente com pelo menos um pedido em South, e "nunca comprou Home" vale para qualquer região. Escrevam essa interpretação no texto.

Perfis do d2 (para a tabela do trabalho):

Dimensão	Valor	Pedidos	Receita	Avaliação média
Região	East	44	46.224,77	3,00
Região	North	66	71.574,05	2,92
Região	South	42	51.187,60	3,10
Região	West	47	47.679,19	2,92
Pagamento	Card	92	95.776,20	2,94
Pagamento	COD	73	83.419,97	2,92

Dimensão	Valor	Pedidos	Receita	Avaliação média
Pagamento	Wallet	34	37.469,44	3,20

5. Metodologia de prova empírica por amostragem

Ideia: antes de confiar no resultado do banco sobre os 199 pedidos, calcular à mão uma amostra pequena e comparar. Se o SQL e a conta manual concordam na amostra e as somas globais fecham, o dado carregado está íntegro.

Passo a passo:

1. **Definir a amostra:** os 20 primeiros pedidos (order_id 10001 a 10020). É a base de teste pequena citada na proposta.
2. **Conferir a fórmula da receita à mão** em alguns pedidos. Exemplo: pedido 10001, 7 × 373,65 × (1 − 0,28) = 2.615,55 × 0,72 = 1.883,196 ≈ **1.883,20**. Pedido 10019: 3 × 434,87 × 0,72 = **939,32**.
3. **Somar a receita e calcular a média das notas da amostra à mão** e contar por categoria.
4. **Rodar o SQL** sobre o mesmo filtro (bloco V8 do arquivo `03_verificacao.sql`).
5. **Comparar** com tolerância de 0,01 (arredondamento de centavos).
6. **Aplicar nos 199 pedidos** conferindo os invariantes: a soma por região e a soma por categoria fecham o total, a junção devolve 199 linhas, não há pedidos órfãos e a receita bate com a fórmula.
7. **Comparar com o dashboard** (mesmos 216.665,61, 199 e 2,98).

Valores esperados da amostra (pedidos 10001 a 10020):

Medida	Valor
Pedidos	20
Receita total	26.497,74
Avaliação média	2,94
Beauty	4 pedidos, 6.283,27
Clothing	10 pedidos, 11.461,63
Electronics	5 pedidos, 7.813,52
Home	1 pedido, 939,32

Valores esperados globais:

Medida	Valor
Pedidos / clientes / produtos	199 / 183 / 4
Receita total	216.665,61
Avaliação média	2,98
Receita por categoria	Beauty 27.673,86 · Clothing 66.234,96 · Electronics 78.728,36 · Home 44.028,43
Pedidos por categoria	Beauty 24 · Clothing 61 · Electronics 73 · Home 41

6. Guião da apresentação (10 slides)

Slide 1 — Título

- Título do trabalho, integrantes, disciplina e data.
- *Fala:* apresentar o tema em uma frase: banco de dados é matemática aplicada.
- *Visual:* capa limpa com o título.

Slide 2 — Problema e objetivo

- Dados inter-relacionados precisam de estrutura (Silberschatz et al., 2012).
- A modelagem nasce de estruturas formais, não só de diagramas.
- Objetivo: ligar conjuntos, relações e funções a um banco real.
- *Fala:* explicar por que a matemática discreta importa para quem programa.
- *Visual:* esquema de três círculos (conjuntos, relações, funções) apontando para uma tabela.

Slide 3 — Conjuntos e produto cartesiano

- Operações ∪, ∩ e −. $A \times B$ e $|A \times B| = |A| \cdot |B|$.
- Tabela = subconjunto de um produto cartesiano.
- Exemplo: Região × Pagamento = 12 pares.
- *Fala:* mostrar que cada linha de tabela é uma tupla.
- *Visual:* tabela 4 × 3 de pares preenchida.

Slide 4 — Relações e mapeamentos (exemplo acadêmico)

- Relação binária $R \subseteq A \times B$.
- 1:N (Professor–Disciplina) e N:M (Aluno–Disciplina, via Matrículas).

- *Fala:* o N:M precisa de uma tabela associativa.
- *Visual:* diagrama ER com Alunos, Disciplinas, Professores e Matrículas.

Slide 5 — Funções: quando uma relação é função

- Domínio, contradomínio e imagem.
- Cada elemento do domínio tem exatamente uma imagem.
- Pedidos → Clientes é função. Clientes → Pedidos não é.
- *Fala:* a chave estrangeira é a implementação de uma função.
- *Visual:* dois diagramas de setas lado a lado (um válido, um inválido).

Slide 6 — Chaves e integridade referencial

- PK, FK e dependência funcional.
- Demonstração: o banco rejeita pedido com cliente inexistente.
- *Fala:* a integridade referencial garante que a função esteja sempre bem definida.
- *Visual:* print da mensagem de erro de violação de FK.

Slide 7 — Normalização até a 3FN

- Uma tabela única vira três: clientes, produtos e pedidos.
- Achado: 11 clientes em mais de uma região, então region fica em pedidos.
- Junção sem perda: 199 linhas.
- *Fala:* a normalização foi guiada pelas dependências funcionais, não por intuição.
- *Visual:* diagrama ER antes e depois (print do Supabase).

Slide 8 — Álgebra relacional e SQL

- σ, π, ⋈, ∪, ∩, − e seus equivalentes em SQL.
- Interseção: clientes 1871 e 1955. Diferença: 29 clientes. União: 91 clientes.
- *Fala:* a junção é uma seleção sobre o produto cartesiano (199 = 199).
- *Visual:* tabela álgebra × SQL × resultado.

Slide 9 — Validação e dashboard

- Amostra de 20 pedidos conferida à mão (receita de 26.497,74).
- Totais: 216.665,61, 199 pedidos e avaliação 2,98.
- *Fala:* o que foi calculado à mão bate com o SQL e com o dashboard.
- *Visual:* print do Looker Studio com cartões, barras por categoria e tabela de auditoria.

Slide 10 — Conclusão e referências

- Conjuntos → relações → funções → tabelas.
- Relevância da matemática discreta. Perspectivas: Big Data e NoSQL.

- Referências.
- *Fala:* fechar com a ideia central e abrir para perguntas.
- *Visual:* linha do tempo ou quadro-resumo dos quatro conceitos.

7. Referências (modelo ABNT)

As referências enviadas estão incompletas ("[S.l.: s.n.]"). Completem com os dados da ficha catalográfica do exemplar que usaram. Modelo:

- SILBERSCHATZ, Abraham; KORTH, Henry F.; SUDARSHAN, S. **Sistema de banco de dados**. [edição]. [cidade]: [editora], 2012.
- DATE, C. J. **Introdução a sistemas de bancos de dados**. [edição]. [cidade]: [editora], 1990.

Não preenchi edição e editora porque não tenho como confirmá-las. Em ABNT, "et al." no texto é aceito, mas na lista final cabe listar os autores conforme a norma adotada pelo professor.

8. Ajustes nos arquivos já existentes

- **Proposta (item 4):** o texto fala em "20 dados" e tem um erro de digitação ("apilicar"). Troquem por: "conjunto de dados de e-commerce com 199 pedidos, sendo uma amostra de 20 pedidos usada na verificação manual antes de aplicar os mesmos critérios ao conjunto completo".
- **Índice (`modelagem_bd.docx`):** adicionar funções, normalização e dashboard conforme a seção 2 deste guia.
- **Número de registros:** usar 199 em todo o texto, nos slides e no dashboard.